

2da etapa: después de las bases

Hasta acá

- Bases de la inteligencia artificial
- Sistemas expertos: modelos y búsqueda
- Ontologías, representación del conocimiento
- Aprendizaje: bias, principios
- Redes Neuronales: minimización del error, representación
- Redes profundas: soluciones, representación, mejoras a la generalización

Desde los principios al funcionamiento

Desde acá

- Ideas distintas para aprender
- Problemas secuenciales: transformers
- Métodos generativos
- Aprendizaje por refuerzo
- Sistemas multiagente

Sólo motivación y bases

Otras formas de aprendizaje

Tipos de aprendizaje tradicionales

Supervised Learning

Data: (x, y)

x is data, y is label

Goal: Learn function to map
 $x \rightarrow y$

Apple example:



This thing is an apple.

Unsupervised Learning

Data: x

x is data, no labels!

Goal: Learn underlying
structure

Apple example:



This thing is like
the other thing.

Reinforcement Learning

Data: state-action pairs

Goal: Maximize future rewards
over many time steps

Apple example:



Eat this thing because it
will keep you alive.

Tipos de aprendizaje tradicionales

- Siempre estamos aprendiendo el problema completo
- Usamos la experiencia previa solo para mejorar los modelos o el pre-procesado
- Usar la experiencia previa siempre fue una de las metas de la IA

Nuevas ideas para aprender

- Aprender modelos generales y usarlos como base para aprender problemas particulares
 - Imitar lo que hacemos acá
- Buscar formas rápidas y eficientes
 - Transfer learning
 - In context learning
 - Few shot learning

Transfer Learning

Transferencia de aprendizaje


- Un modelo (profundo) que logra generalizar muy bien en un problema bastante amplio, en general funciona porque logró una muy buena representación interna.
- Podemos tratar de usar esa representación como punto de partida para resolver nuestro problema particular.
- Reutilizar no es original, siempre se hizo en ciencia e ingeniería, solo era difícil en aprendizaje.
- Se puede aplicar para muchos dominios (no solo imágenes).

Imágenes: Pre entrenamiento sobre ImageNet


1. Train on ImageNet




2. Finetune network on
your own data



Ejemplo con redes convolucionales



Ejemplo con redes convolucionales



	very similar dataset	very different dataset
very little data	Use Linear Classifier on top layer	You're in trouble... Try linear classifier from different stages
quite a lot of data	Finetune a few layers	Finetune a larger number of layers

In-context Learning

In context learning

- Los grandes modelos del lenguaje (LLM) tienen la capacidad de producir salidas correctas ante entradas (prompts) muy largos.
- Al aprender, incorporan no solo información sobre el lenguaje, sino información general sobre el “mundo”
- Aprenden sobre grandes volúmenes de datos tomados de la web, por lo que al aprender el idioma también aprenden mucho del contenido de los datos

In context learning

- Los LLMs entonces tienen algo del “sentido común” o de las “capacidades de razonamiento” que se necesita para resolver problemas inteligentes.
- Ante prompts que incorporan nueva información, son muchas veces capaces de responder con la respuesta más razonable dada la información del prompt y las capacidades adquiridas previamente.

In context learning

- Esta capacidad se puede utilizar para hacer que el modelo “aprenda” tareas muy específicas.
- El método de aprendizaje consiste en colocar la información que se quiere aprender en el prompt, seguido de la pregunta que se quiere responder basado en esa información.
- El aprendizaje no es “permanente”, no se puede utilizar como experiencia para la próxima pregunta
 - A menos que pueda incorporar en el prompt toda la información

In context learning

- La predicción del LLM se produce en el contexto de la información presente en el prompt (más el “sentido común” adquirido al aprender el lenguaje)
- Por eso se llama “aprendizaje en contexto”
- El aprendizaje es instantáneo, de una sola pasada, la clave está en poner la información necesaria en el prompt

In context learning

- En principio, la misma estrategia se podría utilizar para modelos que aprenden o predicen otro tipo de datos
 - Modelos que traducen de sonido a texto, texto a imágenes, videos, etc.